Découverte du Traitement Automatique des Langues

Hors-série 1 : Les expressions régulières

Julien Bezançon

julien.bezancon@univ-lorraine.fr / https://julienbez.github.io



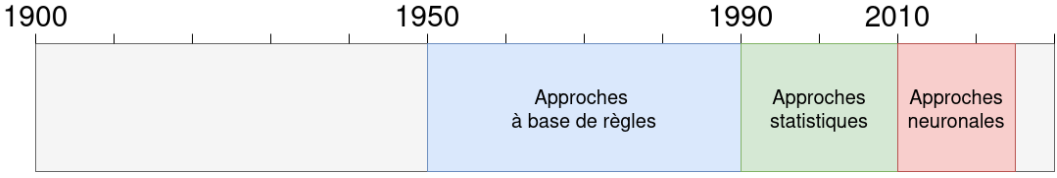


1 Avant de commencer...

2 Approches à base de règles

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Chronologie du TAL



1 Avant de commencer...

2 Approches à base de règles

Approches à base de règles

Objectifs

- On veut traiter du langage avec des machines
- On choisi de donner des règles à ces machines

C'est quoi une règle ?

- Une analyse faite sur un phénomène régulier
- Langue = groupe de règles implicites

Une règle doit être exprimée en langage logique
pour être interprétée par une machine.

Quelles sont les règles pour définir un mot du français ?

Quelles sont les règles pour définir un mot du français ?
Pouvez-vous les formaliser en langage logique ?

Définir un mot

Règles du mot

- Suite de caractères
- Délimité par des espaces
- Possède un sens / un signifié

Cas problématiques

- Tire-bouchon ⇒ un seul mot ?
- Pomme de terre ⇒ un seul mot ?
- IDMC ⇒ suite de caractères, donc c'est un mot ?

Rappel : la tokénisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- Les | étudiants | mangent | un | kebab
- pomme de terre | ou | pomme | de | terre | ?
- tire-bouchon | ou | tire | - | bouchon | ?
- pierre | qui | roule | n' | amasse | pas | mousse | ?

En somme...