

Découverte du Traitement Automatique des Langues

CM 1 : Bienvenue et introduction

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



- 1 Avant de commencer...
- 2 Le TAL, c'est quoi ?
- 3 Comment faire du TAL ?

Moi



Vous me verrez aussi en...

- Data Storage and Retrieval M1
- Prompt Engineering M2
- Software Projects M2
- Written Corpora M2
- Lexicology M2

Ce cours

10 cours magistraux sur le Traitement Automatique des Langues (TAL)

- Le TAL : c'est quoi ?
- Les langues naturelles comme données
- Les grandes approches du TAL
- Traiter et représenter des données langagières
- Le TAL dans notre société

Mode d'évaluation

- Participation orale (10 %)
- Examen final (90 %)
- Peut-être un TD évalué...

Examen final : ???

Les travaux dirigés

Deux intervenantes (pas moi !)

- Clémentine Bleuze (clementine.bleuze@univ-lorraine.fr)
- Iglïka Nikolova-Stoupak (iglika.nikolova-stoupak@univ-lorraine.fr)

Références de ce cours

- Gaël Lejeune (gael.lejeune@sorbonne-universite.fr)
 - cours d'ingénierie des langues
- Xavier Tannier (xavier.tannier@sorbonne-universite.fr)
 - cours d'introduction au TAL¹
- Karën Fort (karen.fort@univ-lorraine.fr)
 - cours et travail sur l'éthique
- Anne-Laure Ligozat (anne-laure.ligozat@lisn.fr)
 - travail sur l'impact environnemental du numérique

¹<https://etal2023.lis-lab.fr/programme/>

- ① Avant de commencer...
- ② Le TAL, c'est quoi ?
- ③ Comment faire du TAL ?

Le TAL, c'est quoi ?

Définition de Wikipédia²

Le traitement automatique des langues (TAL), en anglais *natural language processing* ou *NLP*, est un domaine multidisciplinaire impliquant la linguistique, l'informatique et l'intelligence artificielle, qui vise à créer des outils de traitement des langues naturelles pour diverses applications.

Le TAL cherche à **traiter** la langue naturelle
Le TAL est **multidisciplinaire**

²https://fr.wikipedia.org/wiki/Traitement_automatique_des_langues

Le TAL, c'est quoi ?


Définition de Wikipédia²

Le traitement automatique des langues (TAL), en anglais *natural language processing* ou *NLP*, est un domaine multidisciplinaire impliquant la linguistique, l'informatique et l'intelligence artificielle, qui vise à créer des outils de traitement des langues naturelles pour diverses applications.

Le TAL cherche à **traiter** les langues naturelles
Le TAL est **multidisciplinaire**

²https://fr.wikipedia.org/wiki/Traitement_automatique_des_langues


Un exemple




Source : un article d'Andrew Zola³

³<https://www.techtarget.com/cybersecurity/definition/spam-filter>

Et le TAL, c'est facile ?



Et le TAL, c'est facile ?



Problématique

Le langage naturel est...

- redondant
- ambigu
- implicite
- vivant

- bref, il est naturel

Conséquence : il est difficile à **représenter**

Le langage est redondant

ChatGPT au tribunal : un avocat trompé par l'IA plaide coupable

Etats-Unis: ChatGPT lui souffle des affaires inventées, un avocat dans l'embarras

Un avocat utilise ChatGPT pour préparer un procès : il doit s'excuser car rien n'était vrai dans son dossier


"MON DIEU, JE REGRETTE": L'AVOCAT AYANT UTILISÉ CHATGPT ESTIME S'ÊTRE FAIT AVOIR PAR L'IA

Un avocat américain a utilisé ChatGPT pour préparer un procès... et n'a cité que des faux arrêts

Après avoir utilisé ChatGPT, un avocat fait référence à des affaires qui n'ont jamais eu lieu

Source : Cours d'introduction au TAL de Xavier Tannier

Le langage est ambigu



Le langage est ambigu

- L'humain observe le pigeon. Il pond un oeuf.
 - qui pond un oeuf ?
 - ⇒ à qui fait référence "il" ?

Le langage est ambigu

- L'humain observe le pigeon. Il pond un oeuf.
 - qui pond un oeuf ?
 - ⇒ à qui fait référence "il" ?
- Mangez les enfants !
 - mieux avec la virgule...
 - quel sens avez-vous compris en premier ?

Le langage est ambigu

- L'humain observe le pigeon. Il pond un oeuf.
 - qui pond un oeuf ?
 - ⇒ à qui fait référence "il" ?
- Mangez les enfants !
 - mieux avec la virgule...
 - quel sens avez-vous compris en premier ?
- Il prend des vessies pour des lanternes
 - hein ???
 - les expressions nécessitent une connaissance préalable

Le langage est implicite

 **Mediapart**

Kyiv lutte contre la stratégie de « paralysie » menée par la Russie

La défense antiaérienne de la capitale ukrainienne est à la peine contre les nouvelles méthodes trouvées par l'armée russe pour briser le...

il y a 6 heures



 **Le Club de Mediapart**

Contre le fascisme, l'entraide et l'hospitalité plutôt que les scènes électorales

Nous avons le choix : soit rester hypnotisé-es par la dystopie en cours, par la brutalité qui gouverne la reproduction sociale,...

il y a 7 heures



Titre et chapô d'articles de Médiapart (04/09/2026).

Le langage est vivant

PAS DE DOUTE, LA LANGUE FRANÇAISE S'ENRICHIT... 😊

« Vieux » français	2022
Ainsi	Du coup
Donc	Du coup
Dès lors	Du coup
Tout à coup	Du coup
En conclusion	Du coup
C'est pourquoi	Du coup
Par conséquent	Du coup
Par suite	Du coup
Subséquemment	Du coup
Désormais	Du coup
Aussi	Du coup
Après	Du coup
Soudainement	Du coup
Si je comprends bien	Du coup
Finalement	Du coup

Un meme (source anonyme).

Le langage est vivant

PAS DE DOUTE, LA LANGUE FRANÇAISE S'ENRICHIT... 😊

« Vieux » français	2022
Ainsi	Du coup
Donc	Du coup
Dès lors	Du coup
Tout à coup	Du coup
En conclusion	Du coup
C'est pourquoi	Du coup
Par conséquent	Du coup
Par suite	Du coup
Subséquemment	Du coup
Désormais	Du coup
Aussi	Du coup
Après	Du coup
Soudainement	Du coup
Si je comprends bien	Du coup
Finalement	Du coup

Un meme (source anonyme).

Écriture inclusive, néologie, etc

- aplaventrisme
- prompt
- dinguerie
- quaicoubéh
- ...
- Et vos néologismes ?

Le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn
-----------------------	-------------------------------

Le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn
-----------------------	-------------------------------

Ce qu'elle ne voit et/ou ne comprend pas

Syntaxe (structure)	Êl síla erin lû e-govaned vîn
Signifié (sens)	Une étoile brille sur l'heure de notre rencontre
Prosodie (oralité)	ɛ:l si.la ɛ.rin lu: ɛ go.va.nɛd vi:n
Contexte	<i>Vous êtes un hobbit saluant gracieusement un elfe</i>

Une machine ne comprend pas le langage.
Une machine ne dispose pas de connaissances de notre monde.

Une machine ne comprend pas le langage.
Une machine ne dispose pas de connaissances de notre monde.
On peut donner des données et des règles à une machine pour reproduire des processus cognitifs et linguistiques.

Autres difficultés

Les langues sont nombreuses

- Combien de langues connaissez-vous ?
- Combien de langues dans le monde ?
- Combien de langues en France ?

Les langues sont multimodales

- Écriture (registre, alphabet, etc)
- Parole (ton, prosodie, rythme, etc)
- Gestes (langues des signes, gestes symboliques, etc)
- ...

Les objectifs du TAL

Le TAL, ce n'est pas...

- comprendre du langage
- *prompter* des modèles de langue

Le TAL, ça sert à...

- Traiter des données en langage naturel (principalement écrit et oral)
- Accomplir des tâches en lien avec le langage
- Étudier le fonctionnement du langage

Dans un prochain cours : les applications du TAL

Mais avant... avez-vous remarqué ?

Mais avant... avez-vous remarqué ?
Langue VS Langage

Mais avant... avez-vous remarqué ?
Langue VS Langage

Langage : capacité à communiquer
Langue : outil pour communiquer

Mais avant... avez-vous remarqué ?
Langue VS Langage

Langage : capacité à communiquer
Langue : outil pour communiquer

Écriture et parole : applications de cet outil

- ① Avant de commencer...
- ② Le TAL, c'est quoi ?
- ③ Comment faire du TAL ?**

Langages naturels et non naturels

Pour résumer...

- Humain : langage naturel
- Machine : langage non naturel


Un exemple de langage non naturel

```
sentence = "Hello World"
show_sentence = True

if show_sentence is True:
    print(sentence)
```

Autres exemples : mathématiques, programmes logiques, etc

Exercice : le filtre à spams



Source : un article d'Andrew Zola⁴

⁴<https://www.techtarget.com/cybersecurity/definition/spam-filter>

Exercice : le filtre à spams

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu
- il est envoyé 50 fois en 2 heures
- etc

Prochaine étape : convertir ces observations en consignes pour la machine (= les convertir en langage non naturel)

Exercice : le filtre à spams

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu
- il est envoyé 50 fois en 2 heures
- etc

Prochaine étape : convertir ces observations en consignes pour la machine (= les convertir en langage non naturel)

Le TAL EST multidisciplinaire

Un riche héritier a besoin d'argent

- Une machine ne comprend pas le langage
- Une machine ne dispose pas de connaissances de notre monde
- ⇒ Analyse du message = complexe

Approches envisagées pour contourner ces problématiques

- Approches à base de règles (linguistique)
- Approches statistiques (mathématiques)
- Approches neuronales (neurologie)

Si on comprend un langage, on pourrait le définir
pour qu'une machine le comprenne (?)