

Découverte du Traitement Automatique des Langues

CM 2 : Tâches et applications du TAL

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



① Avant de commencer...

② Applications VS tâches

③ Grandes tâches du TAL

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Le TAL...

- Traite les langues naturelles
- Est multidisciplinaire

Le langage...

- Est redondant, ambigu et implicite
- Abrite de nombreux phénomènes

Une machine...

- Ne comprend pas le langage
- Pas de connaissances du monde



① Avant de commencer...

② Applications VS tâches

③ Grandes tâches du TAL

À votre avis, quelles sont les applications du TAL ?
(Un lien Wooclap arrive...)

Les applications du TAL

Avec le TAL, on peut mettre en place :

- des agents conversationnels
- des systèmes de filtrage de spams
- des assistants vocaux
- des outils de correction automatique
- des outils de résumé automatique
- etc


Les applications du TAL

Avec le TAL, on peut mettre en place :

- des agents conversationnels
- des systèmes de filtrage de spams
- des assistants vocaux
- des outils de correction automatique
- des outils de résumé automatique
- etc

Pour réussir à mettre en place ces applications,
il faut d'abord les découper en tâches

Un exemple



Source : un article d'Andrew Zola¹

¹<https://www.techtarget.com/cybersecurity/definition/spam-filter>

Un exemple

Un mail est un spam si...

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"

⇒ recherche d'information

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent

⇒ recherche d'information

⇒ analyse sémantique

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu

⇒ recherche d'information

⇒ analyse sémantique

⇒ base de données

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu
- il est envoyé 50 fois en 2 heures

⇒ recherche d'information

⇒ analyse sémantique

⇒ base de données

⇒ similarité

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu
- il est envoyé 50 fois en 2 heures
- etc

⇒ recherche d'information

⇒ analyse sémantique

⇒ base de données

⇒ similarité

...

À votre avis, quelles sont les tâches du TAL ?
(Un lien Wooclap arrive...)

Les tâches du TAL

Le TAL se découpe en une multitude de tâches

- Classification de données
- Extraction d'information
- Traduction automatique
- Analyse syntaxique
- Systèmes de Q&A
- etc

Les tâches du TAL

Le TAL se découpe en une multitude de tâches

- Classification de données
- Extraction d'information
- Traduction automatique
- Analyse syntaxique
- Systèmes de Q&A
- etc

Pourquoi existe-t-il autant de tâches en TAL ?

Les tâches du TAL

Rappel : le langage est naturel

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite
- Phénomènes linguistiques (néologie, coréférence, etc)

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite
- Phénomènes linguistiques (néologie, coréférence, etc)
- Machine $\neq$ Humain

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite
- Phénomènes linguistiques (néologie, coréférence, etc)
- Machine $\neq$ Humain

Il existe BEAUCOUP de phénomènes linguistiques,
qui sont tous interconnectés.

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite
- Phénomènes linguistiques (néologie, coréférence, etc)
- Machine $\neq$ Humain

Il existe BEAUCOUP de phénomènes linguistiques,
qui sont tous interconnectés.

La séparation en tâches n'est qu'une façon
d'avancer sans devoir se préoccuper de tout à la fois.

Quels sont les autres avantages du découpage en tâches ?

Quels sont les autres avantages du découpage en tâches ?

Comparer et évaluer des approches et méthodologies.

Dans un prochain cours : évaluation en TAL

Pour résumer...

Tâche

Pour résumer...

Tâche

- Définie par les scientifiques

Pour résumer...

Tâche

- Définie par les scientifiques
- Recherche à répondre à une problématique précise

Pour résumer...

Tâche

- Définie par les scientifiques
- Recherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application

Pour résumer...

Tâche

- Définie par les scientifiques
- Recherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application

- Définie par des individus

Pour résumer...

Tâche

- Définie par les scientifiques
- Recherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application

- Définie par des individus
- Recherche à répondre à un "besoin"

Pour résumer...

Tâche

- Définie par les scientifiques
- Recherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application

- Définie par des individus
- Recherche à répondre à un "besoin"
- Combine généralement plusieurs tâches

Pour résumer...

Tâche

- Définie par les scientifiques
- Cherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application


- Définie par des individus
- Cherche à répondre à un "besoin"
- Combine généralement plusieurs tâches

Dans ce cours, nous nous intéressons aux tâches du TAL.


- ① Avant de commencer...
- ② Applications VS tâches
- ③ Grandes tâches du TAL**

Classification de textes

Classification de textes



Classification de textes



Applications :

- Ranger des récits par catégorie
- Détecter des spams

Résumé automatique

Résumé automatique

Il était une fois une petite fille de village, la plus jolie qu'on eût su voir ; sa mère en était folle, et sa mère-grand plus folle encore. Cette bonne femme lui fit faire un petit chaperon rouge, qui lui seyait si bien que partout on l'appelait le petit Chaperon rouge. Un jour, [...]



Dans cette histoire, une petite fille habillée en rouge va rendre visite à sa grand-mère. Ça tourne mal, mais ça fini bien !

Résumé automatique

Il était une fois une petite fille de village, la plus jolie qu'on eût su voir ; sa mère en était folle, et sa mère-grand plus folle encore. Cette bonne femme lui fit faire un petit chaperon rouge, qui lui seyait si bien que partout on l'appelait le petit Chaperon rouge. Un jour, [...]




Dans cette histoire, une petite fille habillée en rouge va rendre visite à sa grand-mère. Ça tourne mal, mais ça fini bien !

Applications :


- Comptes-rendus automatiques
- Synthèse d'information

Analyse de sentiments

Analyse de sentiments



Analyse de sentiments



Applications :

- Analyse de réputation
- Enquête de satisfaction

Similarité textuelle

Similarité textuelle

Bonjour, je suis étudiant A. Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

Bonjour, je m'appelle étudiant B. Aujourd'hui je vais vous dire pourquoi plagier, c'est pas bien. Dans cet exposé, je vais ...



Similarité : 0.70

Similarité textuelle

Bonjour, je suis étudiant A. Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

Bonjour, je m'appelle étudiant B. Aujourd'hui je vais vous dire pourquoi plagier, c'est pas bien. Dans cet exposé, je vais ...




Similarité : 0.70

Applications :


- Détection de plagiat
- Suppression de duplicatas

Recherche d'information

Recherche d'information



Recherche d'information



Applications :

- Moteur de recherche
- Fouille dans des jeux de données

Désidentification

Désidentification

Monsieur ***** souffre de lésions au niveau des bras suite à un accident de vélo. Ses lésions sont à surveiller étant donné que monsieur ***** est très âgé.

Désidentification

Monsieur ***** souffre de lésions au niveau des bras suite à un accident de vélo. Ses lésions sont à surveiller étant donné que monsieur ***** est très agé.

Applications :

- Protection de la vie privée
- Anonymisation de données

Reconnaissance d'entités nommées

²https://en.wikipedia.org/wiki/Entity_linking

Reconnaissance d'entités nommées

“Paris is the capital of France”



wikipedia.org/wiki/Paris



wikipedia.org/wiki/France

Source : Wikipédia²

²https://en.wikipedia.org/wiki/Entity_linking

Reconnaissance d'entités nommées

“Paris is the capital of France”



wikipedia.org/wiki/Paris



wikipedia.org/wiki/France

Source : Wikipédia²


Applications :

- Recherche de noms de maladies
- Veille informatique

²https://en.wikipedia.org/wiki/Entity_linking


Traduction automatique

Traduction automatique



Bonjour	→	Hello
Hello	→	Καλημέρα
Καλημέρα	→	صباح الخير
صباح الخير	→	早上好

Traduction automatique



Bonjour	→	Hello
Hello	→	Καλημέρα
Καλημέρα	→	صباح الخير
صباح الخير	→	早上好

Applications :

- Traduction en temps réel
- Communication

Systèmes de question / réponse

Systèmes de question / réponse

Quelle est la capitale de la France ?



Paris

Qui a réalisé le film *Blade Runner* ?



Ridley Scott

Systèmes de question / réponse

Quelle est la capitale de la France ?



Paris

Qui a réalisé le film *Blade Runner* ?



Ridley Scott

Applications :

- Système de recommandation
- Support client

Correction automatique

³<https://languagetool.org/>

Correction automatique

He is neither rich , nor poor.

- **Punctuation**

There appears to be an unneeded comma here.

“Neither...nor” is a correlative conjunction,
so a comma should not separate the pair.



Source : LanguageTool³

³<https://languagetool.org/>

Correction automatique

He is neither rich , nor poor.

● Punctuation

There appears to be an unneeded comma here.
“Neither...nor” is a correlative conjunction,
so a comma should not separate the pair.



Source : LanguageTool³

Applications :


- Correction en temps réel
- Suggestions de mise en forme

³<https://languagetool.org/>


Peut-on traiter autre chose que du texte ?

Classification d'images

Classification d'images



Classification d'images




Applications :


- Système de détection
- Tri d'images

Synthèse de la parole

Synthèse de la parole




Synthèse de la parole



Applications :

- Assistants vocaux
- Dictée vocale

Spoil : cours sur le traitement des données



Exercices

Tâche ou application ?

- Moteur de recherche
- Recherche d'information
- Résumé automatique
- Traduction automatique
- Étiquetage morphosyntaxique

Exercices

Tâche ou application ?

- Moteur de recherche $\Rightarrow$ application
- Recherche d'information $\Rightarrow$ tâche
- Résumé automatique $\Rightarrow$ les deux
- Traduction automatique $\Rightarrow$ les deux
- Étiquetage morphosyntaxique $\Rightarrow$ tâche et technique

Questions

- Qu'est-ce qui est nécessaire à la réalisation de n'importe quelle tâche en TAL ?
- Quelles tâches et quelles données pour un moteur de recherche ?

Doggy Bag

Tâche VS application

- Tâche = problématique précise
- Application = plusieurs tâches

Tâches du TAL

- Classification de textes
- Résumé automatique
- Analyse syntaxique
- Similarité
- ...

