

Découverte du Traitement Automatique des Langues

CM 2 : Tâches classiques du TAL et leurs applications

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



① Avant de commencer...

② Applications VS tâches

③ Grandes tâches du TAL

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Le TAL...

- Traite les langues naturelles
- Est multidisciplinaire

Le langage...

- Est redondant, ambigu et implicite
- Abrite de nombreux phénomènes

Une machine...

- Ne comprend pas le langage
- Pas de connaissances du monde



① Avant de commencer...

② Applications VS tâches

③ Grandes tâches du TAL


Les applications du TAL

Avec le TAL, on peut mettre en place :

- des agents conversationnels
- des systèmes de filtrage de spams
- des assistants vocaux
- des outils de correction automatique
- des outils de résumé automatique
- etc

Pour réussir à mettre en place ces applications,
il faut d'abord les découper en tâches

Un exemple



Source : un article d'Andrew Zola¹

¹<https://www.techtarget.com/cybersecurity/definition/spam-filter>

Un exemple

Un mail est un spam si...

- il contient le mot "urgent"
- un riche héritier a besoin d'argent
- le domaine mail de l'envoyeur est inconnu
- il est envoyé 50 fois en 2 heures
- etc

⇒ recherche d'information

⇒ analyse sémantique

⇒ base de données

⇒ similarité

...

Les tâches du TAL

Le TAL se découpe en une multitude de tâches

- Classification de données
- Extraction d'information
- Traduction automatique
- Analyse syntaxique
- Systèmes de Q&A
- Big Data
- etc

Pourquoi existe-t-il autant de tâches en TAL ?

Les tâches du TAL

Rappel : le langage est naturel

- Redondant, ambigu, implicite
- Phénomènes linguistiques (néologie, coréférence, etc)
- Machine $\neq$ Humain

Il existe BEAUCOUP de phénomènes linguistiques,
qui sont tous interconnectés.

La séparation en tâches n'est qu'une façon
d'avancer sans devoir se préoccuper de tout à la fois.

Pour résumer...

Tâche

- Définie par les scientifiques
- Cherche à répondre à une problématique précise
- Restreinte au cadre de la recherche (?)

Application

- Définie par des individus
- Cherche à répondre à un "besoin"
- Combine généralement plusieurs tâches

Dans ce cours, nous nous intéressons aux tâches du TAL.


① Avant de commencer...

② Applications VS tâches

③ Grandes tâches du TAL

À votre avis, quelles sont les tâches du TAL ?
(Un lien Wooclap arrive...)

Classification de textes



Applications :

- Ranger des récits par catégorie
- Détecter des spams
- Trier des textes par langue

Résumé automatique

Il était une fois une petite fille de village, la plus jolie qu'on eût su voir ; sa mère en était folle, et sa mère-grand plus folle encore. Cette bonne femme lui fit faire un petit chaperon rouge, qui lui seyait si bien que partout on l'appelait le petit Chaperon rouge. Un jour, [...]




Dans cette histoire, une petite fille habillée en rouge va rendre visite à sa grand-mère. Ça tourne mal, mais ça fini bien !

Applications :

- Comptes-rendus automatiques
- Extraction de mots-clefs
- Synthèse de l'information

Analyse syntaxique



Applications :

- Analyse linguistique
- Contribue à d'autres tâches

Similarité textuelle

Bonjour, je suis étudiant A. Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

Bonjour, je m'appelle étudiant B. Aujourd'hui je vais vous dire pourquoi plagier, c'est pas bien. Dans cet exposé, je vais ...




Similarité : 0.70

Applications :

- Détection de plagiat
- Regroupement de textes similaires

Recherche d'information



Applications :

- Moteur de recherche
- Fouille dans des jeux de données
- Système de recommandation

Désidentification

Monsieur ***** souffre de lésions au niveau des bras suite à un accident de vélo qui a eu lieu rue ***** à *****. Ses lésions sont à surveiller étant donné que monsieur ***** est *****.

Applications :

- Protection de la vie privée
- Anonymisation de données

Reconnaissance d'entités nommées

“Paris is the capital of France”




Source : Wikipédia²

Applications :

- Recherche de noms de maladies
- Veille informatique
- Résumé automatique
- Mise en relation d'entités

²https://en.wikipedia.org/wiki/Entity_linking

Traduction automatique



Bonjour	→	Hello
Hello	→	Καλημέρα
Καλημέρα	→	صباح الخير
صباح الخير	→	早上好

Applications :

- Traduction en temps réel
- Communication

Systèmes de question / réponse

Quelle est la capitale de la France ?



Paris

Qui a réalisé le film *Blade Runner* ?



Ridley Scott

Applications :

- Moteur de recherche
- Support client

Correction automatique

He is neither rich , nor poor.

● Punctuation

There appears to be an unneeded comma here.
“Neither...nor” is a correlative conjunction,
so a comma should not separate the pair.



Applications :


- Correction en temps réel
- Suggestions de mise en forme

Source : LanguageTool³

³<https://languagetool.org/>

Peut-on traiter autre chose que du texte ?


Classification d'images



Applications :

- Système de détection de tumeurs
- Tri d'images
- Description d'images


Synthèse de la parole



Applications :

- Assistants vocaux
- Dictée vocale
- Recherche vocale

Spoil : cours sur le traitement des données



Exposés en groupe

Les consignes

- Par groupe de 5 maximum
- 20-30 minutes de réflexion / préparation
- 5 minutes de présentation (minimum 1 minute / étudiant)

L'exposé

- Quelle est la problématique ?
- Quelle tâche pour répondre à cette problématique ?
- Quelles sont les données utilisées ?
- Quel est le résultat attendu ?

Doggy Bag

Tâche VS application

- Tâche : problématique précise
- Application : répond à un "besoin"

Tâches du TAL

- Classification de textes
- Résumé automatique
- Analyse syntaxique
- Similarité textuelle
- Recherche d'information
- ...

