

Découverte du Traitement Automatique des Langues

CM 3 : De la linguistique au TAL

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



- ➊ Avant de commencer...
- ➋ Introduction à la linguistique
- ➌ Techniques du TAL

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Tâche VS application

- Tâche = problématique précise
- Application = plusieurs tâches

Tâches du TAL

- Classification de textes
- Résumé automatique
- Analyse syntaxique
- Similarité
- ...



- ① Avant de commencer...
- ② Introduction à la linguistique
- ③ Techniques du TAL

Rappel : le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn
-----------------------	-------------------------------

Ce qu'elle ne voit et/ou ne comprend pas

Syntaxe (structure)	Êl síla erin lû e-govaned vîn
Signifié (sens)	Une étoile brille sur l'heure de notre rencontre
Prosodie (oralité)	<i>ɛ:l si.la ɛ.rin lu: ɛ go.va.nɛd vi:n</i>
Contexte	<i>Vous êtes un hobbit saluant gracieusement un elfe</i>

Vu également : le langage est redondant, ambigu, implicite...

Vu également : le langage est redondant, ambigu, implicite...

Afin de traiter du langage à l'aide d'une machine,
on a besoin d'une meilleure compréhension du langage.

La linguistique, c'est quoi ?

Définition de Wikipédia¹

La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

¹<https://fr.wikipedia.org/wiki/Linguistique>

La linguistique, c'est quoi ?

Définition de Wikipédia¹

La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

Si on comprend un langage, on pourrait le définir
pour qu'une machine le comprenne (?)

¹<https://fr.wikipedia.org/wiki/Linguistique>

Niveaux d'analyse linguistique

5 grands niveaux d'analyse

- Phonologie
- Morphologie
- Syntaxe
- Sémantique
- Pragmatique

Phonologie

Objectif(s)

- Étudie l'organisation des sons
- Unité minimale : le phonème

Exemples

- J'en veux plus !
- J'ai égaré mes fils...

Morphologie

Objectif(s)

- Étudie la forme des mots
- Unité minimale : le morphème

Exemples

- Autossa (dans l'auto) VS autossaniko (dans mon auto)
- Ses cours VS ces cours

Syntaxe

Objectif(s)

- Étudie les combinaisons de mots (phrases, syntagmes, paragraphes, etc)
- Comment ? En attribuant à chaque mot sa classe grammaticale

Exemples

- Je la regarde $\Rightarrow$ la : pronom ou déterminant ?
- Jean regarde la fille avec le télescope

Sémantique

Objectif(s)

- Étudie le sens d'un mot / d'une combinaison de mots
- Unité minimale : le sème

Exemples

- Il tient la porte
- Étoile : célébrité ou astre ?

Pragmatique

Objectif(s)

- Étudie le contexte d'un mot / d'une combinaison de mots
- Contexte : n'est pas limité au langage (lieu, histoire, etc)

Exemples

- La pièce est dans le porte monnaie
- C'est une armoire à glace !

Pour résumer...

5 grands niveaux d'analyse

- Phonologie $\Rightarrow$ organisation des sons
- Morphologie $\Rightarrow$ forme des mots
- Syntaxe $\Rightarrow$ combinaisons de mots
- Sémantique $\Rightarrow$ sens d'un mot / d'une combinaison
- Pragmatique $\Rightarrow$ contexte d'un mot / d'une combinaison

Modéliser la langue permet de mieux gérer les ambiguïtés.
Techniques du TAL $\approx$ applications de ces analyses.

Exercices

Analysez les énoncés suivants

-

- ① Avant de commencer...
- ② Introduction à la linguistique
- ③ Techniques du TAL**

Segmentation

Objectif(s)

- Découper un énoncé en phrases / paragraphes
- Permet une analyse plus fine de l'énoncé

Exemples

Bonjour, je suis étudiant A.
Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

- ⇒
- Bonjour, je suis étudiant A.
 - Aujourd'hui je vais ...
 - Dans cet exposé, je vais ...

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- Les étudiants mangent un kebab
- pomme de terre ou pomme de terre ?
- tire-bouchon ou tire - bouchon ?
- pierre qui roule n'amasse pas mousse ?

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- Verbe : suis, es, est $\Rightarrow$ être
- Nom : maison, maisonnette, maisons $\Rightarrow$ maison

La lemmatisation n'agrège que des variantes flexionnelles.
chevaux $\Rightarrow$ cheval | chevalier $\neq$ cheval

Racinisation

Objectif(s)


- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- cheval, chevaux, chevalier, chevalerie ⇒ cheva
- vais, vas, va, allons, allez, vont ≠ aller

Plus rapide à mettre en place mais moins précise.
avions (verbe) vs avions (nom)

Étiquetage morphosyntaxique



Objectif(s)

- Associer un mot à sa catégorie
- Identifier des structures
- Permet de gérer les ambiguïtés

Exemples

- vers, or, pouvoir, ...

Exercices

Traitez les énoncés suivants

-

Limites

Les techniques du TAL sont limitées

- Des ambiguïtés persistent
- Traiter une langue $\neq$ traiter toutes les langues
- JAMAIS parfaites (90 % = environs une faute par phrase)