Découverte du Traitement Automatique des Langues

CM 3 : De la linguistique au TAL

Julien Bezançon

julien.bezancon@univ-lorraine.fr / https://julienbez.github.io

Institut des sciences du Digital Management & Cognition

COMPOSANTE DE L'UNIVERSITÉ DE LORRAINE

Loria

1 Avant de commencer...

2 Introduction à la linguistique

3 Techniques du TAL

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Tâche VS application

- Tâche = problématique précise
- Application = plusieurs tâches

Tâches du TAL

- Classification de textes
- Résumé automatique
- Analyse syntaxique
- Similarité
- ...



1 Avant de commencer...

2 Introduction à la linguistique

3 Techniques du TAL

Rappel : le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn

Ce qu'elle ne voit et/ou ne comprend pas

Syntaxe (structure)	Êl síla erin | lû e-govaned vîn
Signifié (sens)	Une étoile brille sur l'heure de notre rencontre
Prosodie (oralité)	*ɛ:l si.la ɛ.rin lu: ɛ go.va.nɛd vi:n*
Contexte	*Vous êtes un hobbit saluant gracieusement un elfe*

Vu également : le langage est redondant, ambigu, implicite...

Vu également : le langage est redondant, ambigu, implicite...

Afin de traiter du langage à l'aide d'une machine,
on a besoin d'une meilleure compréhension du langage.

La linguistique, c'est quoi ?

Définition de Wikipédia[1]

> La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

[1] `https://fr.wikipedia.org/wiki/Linguistique`

La linguistique, c'est quoi ?

Définition de Wikipédia[1]

La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

Si on comprend un langage, on pourrait le définir pour qu'une machine le comprenne (?)

[1] `https://fr.wikipedia.org/wiki/Linguistique`

Niveaux d'analyse linguistique

5 grands niveaux d'analyse

Niveaux d'analyse linguistique

5 grands niveaux d'analyse

- Phonologie
- Morphologie
- Syntaxe
- Sémantique
- Pragmatique

Phonologie

Phonologie

Objectif(s)

- Étudie l'organisation des sons
- Unité minimale : le phonème

Exemples

- J'en veux plus !
- J'ai égaré mes fils...

Voyelles		Consonnes	
Orales		[p]	pâle, papa
[i]	vie, cygne	[b]	bu, tube
[e] fermé	blé, parler	[t]	tulle, pâté
[ɛ] ouvert	merci, mère, faire	[d]	dent, ardu
[a] antérieur	plat, patte	[k]	car, sac, coq, quoi, képi
[ɑ] postérieur	pâte, théâtre	[g]	gare, baguette
[o] fermé	moto, beau, faux	[f]	foire, neuf, pharmacie
[ɔ] ouvert	fort, motte, porte	[v]	violon, grève
[y]	vertu, charrue	[s]	sol, face, lasse, nation, six, scène
[u]	fou, bijou	[z]	raison, bise, zèbre
[ø] fermé	feu, deux	[ʃ]	charme, fiche
[œ] ouvert	peur, meuble, leurre	[ʒ]	jurer, gentil
[ə] caduc	cheval, épicerie	[l]	lune, sol
Nasales		[R]	ruse, finir
[ɑ̃]	banc, sans, vent	[m]	maman, femme
[ɔ̃]	bon, sombre	[n]	nid, bonne
[ɛ̃]	matin, plein, sain	[ɲ]	agneau, champignon
[œ̃]	lundi, brun, parfum	**Semi-consonnes**	
		[j]	paille, feuille
		[w]	ouest, toi [twa], poire [pwaR]
		[ɥ]	huile, fuir

Source : `https://www.digischool.fr/cours/les-phonemes-du-francais-2`

Morphologie

Morphologie

Objectif(s)

- Étudie la forme des mots
- Unité minimale : le morphème

Flexions

- vais, vas, va, etc
- maisons, maisonnettes

Dérivations

- faire, faisable (suffixation)
- infaisable (préfixation)

Compositions

- appendicetomie
- appendice + ectomie

Emprunts

- abricot (origine : arabe)
- embarcation (origine : italien)

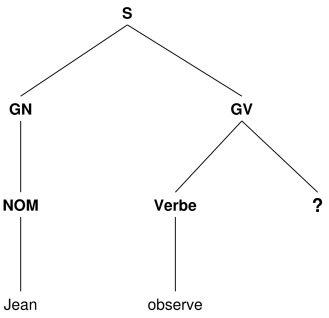
Syntaxe

Syntaxe

Objectif(s)

- Étudie les combinaisons de mots (phrases, syntagmes, paragraphes, etc)
- Comment ? En attribuant à chaque mot sa classe grammaticale

Jean observe	la fille	avec le téléscope
Jean observe	la fille avec le téléscope	



Sémantique

Sémantique

Objectif(s)

- Étudie le sens d'un mot / d'une combinaison de mots
- Unité minimale : le sème

L'analyse sémantique s'appuie entre autre sur...

- le contexte : il tient la porte
- la polysémie : étoile ⇒ célébrité ou astre ?
- la syntaxe : Jean observe la jeune fille avec le téléscope

Les niveaux d'analyse sont interdépendants.

Pragmatique

Pragmatique

Objectif(s)

- Étudie le contexte d'un mot / d'une combinaison de mots
- Contexte : n'est pas limité au langage (lieu, histoire, etc)

Exemples

- La pièce est dans le porte monnaie
  - ici, pièce = argent
  - cotexte VS contexte
- Il fait froid ici...
  - cotexte : ne nous apprend rien
  - contexte : je m'adresse à la personne à côté de la fenêtre ouverte
- C'est une armoire à glace !
- Moi, ma mère, c'est de la moquette

Pour résumer...

5 grands niveaux d'analyse

- Phonologie ⇒ organisation des sons
- Morphologie ⇒ forme des mots
- Syntaxe ⇒ combinaisons de mots
- Sémantique ⇒ sens d'un mot / d'une combinaison
- Pragmatique ⇒ contexte d'un mot / d'une combinaison

Pour résumer...

5 grands niveaux d'analyse

- Phonologie ⇒ organisation des sons
- Morphologie ⇒ forme des mots
- Syntaxe ⇒ combinaisons de mots
- Sémantique ⇒ sens d'un mot / d'une combinaison
- Pragmatique ⇒ contexte d'un mot / d'une combinaison

Modéliser la langue permet de mieux gérer les ambiguïtés.

Pour résumer...

5 grands niveaux d'analyse

- Phonologie ⇒ organisation des sons
- Morphologie ⇒ forme des mots
- Syntaxe ⇒ combinaisons de mots
- Sémantique ⇒ sens d'un mot / d'une combinaison
- Pragmatique ⇒ contexte d'un mot / d'une combinaison

Modéliser la langue permet de mieux gérer les ambiguïtés.
Techniques du TAL ≈ applications de ces analyses.

Exercice

Analysez les énoncés suivants

- Ça fait du bien quand on est lessivés
- T'es vraiment un chips type
- Vous allez avoir des papillons dans le ventre
- *It's raining nems*
- On est champignons d'Europe

Exercice

Analysez les énoncés suivants

- Ça fait du bien quand on est lessivés
- T'es vraiment un chips type
- Vous allez avoir des papillons dans le ventre
- *It's raining nems*
- On est champignons d'Europe

Monoprix vend...

⇒ de la lessive
⇒ des chips
⇒ des pâtes farfalles
⇒ des nems
⇒ des champignons

1 Avant de commencer...

2 Introduction à la linguistique

3 Techniques du TAL

Segmentation

Segmentation

Objectif(s)

- Découper un énoncé en phrases / paragraphes
- Permet une analyse plus fine de l'énoncé

Segmentation

Objectif(s)

- Découper un énoncé en phrases / paragraphes
- Permet une analyse plus fine de l'énoncé

Exemples

Bonjour, je suis étudiant A. Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

⇒

- Bonjour, je suis étudiant A.
- Aujourd'hui je vais ...
- Dans cet exposé, je vais ...

Tokenisation

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- | Les | étudiants | mangent | un | kebab |

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- [Les] [étudiants] [mangent] [un] [kebab]
- [pomme de terre] ou [pomme] [de] [terre] ?

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- [Les] [étudiants] [mangent] [un] [kebab]
- [pomme de terre] ou [pomme] [de] [terre] ?
- [tire-bouchon] ou [tire] [-] [bouchon] ?

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- [Les] [étudiants] [mangent] [un] [kebab]
- [pomme de terre] ou [pomme] [de] [terre] ?
- [tire-bouchon] ou [tire] [-] [bouchon] ?
- [pierre] [qui] [roule] [n'] [amasse] [pas] [mousse] ?

Lemmatisation

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- Verbe : suis, es, est ⇒ être
- Nom : maison, maisonnette, maisons ⇒ maison

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- Verbe : suis, es, est ⇒ être
- Nom : maison, maisonnette, maisons ⇒ maison

La lemmatisation n'agrège que des variantes flexionnelles.

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- Verbe : suis, es, est ⇒ être
- Nom : maison, maisonnette, maisons ⇒ maison

La lemmatisation n'agrège que des variantes flexionnelles.

chevaux ⇒ cheval | chevalier ≠ cheval

Racinisation

Racinisation

Objectif(s)

- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Racinisation

Objectif(s)

- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- cheval, chevaux, chevalier, chevalerie ⇒ cheva
- vais, vas, va, allons, allez, vont ≠ aller

Racinisation

Objectif(s)

- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- cheval, chevaux, chevalier, chevalerie ⇒ cheva
- vais, vas, va, allons, allez, vont ≠ aller

Plus rapide à mettre en place mais moins précise.

Racinisation

Objectif(s)

- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

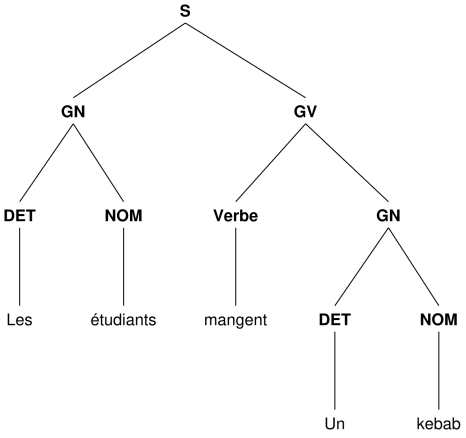
- cheval, chevaux, chevalier, chevalerie ⇒ cheva
- vais, vas, va, allons, allez, vont ≠ aller

Plus rapide à mettre en place mais moins précise.

avions (verbe) vs avions (nom)

Étiquetage morphosyntaxique

Étiquetage morphosyntaxique



Objectif(s)

- Associer un mot à sa catégorie
- Identifier des structures
- Permet de gérer les ambiguïtés

Exemples

- vers, or, pouvoir, ...
- ⇒ homonymes !

Exercice

Tokenisez les énoncés suivants

- J'ai pris un rendez-vous sur le site de doctolib : `https://www.doctolib.fr/` !
- Budget 2027 : Sébastien Lecornu utilisera-t-il le 49.3 ?
- Jean-Louis travaille à New York. Il étudie les récits de la guerre de 14-18.

Limites

Les techniques du TAL sont limitées

- Des ambiguïtés persistent toujours
- Traiter une langue ne revient pas à traiter toutes les langues
- Les techniques du TAL ne sont JAMAIS parfaites

Des inégalités existent

- Langues pas/peu dôtées VS langues dôtées
- Langues sans système d'écriture

Des ambiguïtés persistent

Quelques exemples d'ambiguïtés

- J'en veux plus !
- Appendicetomie
- *He kicked the bucket.*
- Jean observe son père avec ses jumelles.
- Le robot amuse le chat. Il bouge mécaniquement.

Autres types d'ambiguïtés :
ironie, sarcasme, humour, plurilinguisme, etc

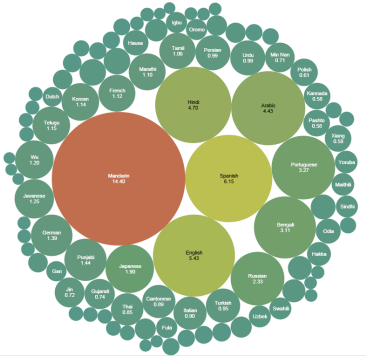
Des ambiguïtés persistent

Quelques exemples d'ambiguïtés

- J'en veux plus ! ⇒ quel "plus" ?
- Appendicetomie ⇒ appendice + ectomie
- *He kicked the bucket.* ⇒ expression ou description ?
- Jean observe son père avec ses jumelles. ⇒ 3 interprétations
- Le robot amuse le chat. Il bouge mécaniquement. ⇒ coréférence

Autres types d'ambiguïtés :
ironie, sarcasme, humour, plurilinguisme, etc

Traiter une langue ≠ traiter LES langues

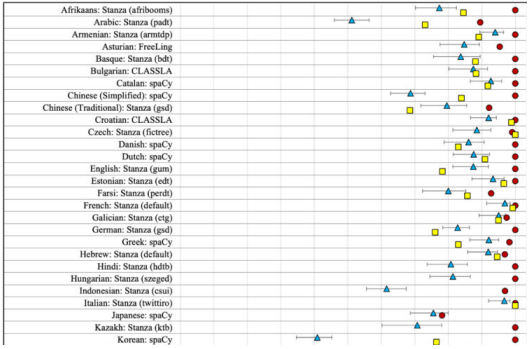


Source : Wikipedia[2]

Evlerimdekiler (turc) ⇒ *ceux qui sont dans les maisons*

[2] `https://en.wikipedia.org/wiki/List_of_languages_by_total_number_of_speakers`

Techniques imparfaites



Source : Loretta et. al, 2026[3]

Étiquetage morphosyntaxique

- 90 %, c'est quoi ?
- Taux d'annotations correctes
- Une phrase en Fr = 10-15 mots
- 90 % ⇒ 1 faute par phrase

[3] https://www.sciencedirect.com/science/article/pii/S2949719126000312

Exercice SUR PAPIER !

Procédez à un étiquetage morphosyntaxique de la phrase suivante

- Nous portions des portions.
- Aujourd'hui, nous mangeons des pommes de terre.
- L'histoire, c'est passionant !
- Le rapporteur de l'organisation des nations unies a exprimé ses craintes.

Exercice SUR PAPIER !

Procédez à un étiquetage morphosyntaxique de la phrase suivante

- Nous portions des portions.
- Aujourd'hui, nous mangeons des pommes de terre.
- L'histoire, c'est passionant !
- Le rapporteur de l'organisation des nations unies a exprimé ses craintes.

Échangez votre feuille avec celle d'un voisin.
Êtes vous d'accord ? Sinon, pourquoi ?

Doggy Bag

Analyse linguistique

- Phonétique
- Morphologique
- Syntaxique
- Sémantique
- Pragmatique

Techniques du TAL

- Segmentation
- Tokenisation
- Lemmatisation, racinisation
- Étiquetage morphosyntaxique

