

Découverte du Traitement Automatique des Langues

CM 3 : De la linguistique au TAL

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



- ① Avant de commencer...
- ② Introduction à la linguistique
- ③ Techniques du TAL

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Tâche VS application

- Tâche = problématique précise
- Application = plusieurs tâches

Tâches du TAL

- Classification de textes
- Résumé automatique
- Analyse syntaxique
- Similarité
- ...



① Avant de commencer...

② Introduction à la linguistique

③ Techniques du TAL

Rappel : le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn
-----------------------	-------------------------------

Ce qu'elle ne voit et/ou ne comprend pas

Syntaxe (structure)	Êl síla erin lû e-govaned vîn
Signifié (sens)	Une étoile brille sur l'heure de notre rencontre
Prosodie (oralité)	<i>ɛ:l si.la ɛ.rin lu: ɛ go.va.nɛd vi:n</i>
Contexte	<i>Vous êtes un hobbit saluant gracieusement un elfe</i>

Vu également : le langage est redondant, ambigu, implicite...

Vu également : le langage est redondant, ambigu, implicite...

Afin de traiter du langage à l'aide d'une machine,
on a besoin d'une meilleure compréhension du langage.

La linguistique, c'est quoi ?

Définition de Wikipédia¹

La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

¹<https://fr.wikipedia.org/wiki/Linguistique>

La linguistique, c'est quoi ?

Définition de Wikipédia¹

La linguistique est une discipline scientifique s'intéressant à l'étude du langage. Elle n'est pas prescriptive mais descriptive. Elle se contente de décrire la langue telle qu'elle est et non telle qu'elle devrait être.

Si on comprend un langage, on pourrait le définir
pour qu'une machine le comprenne (?)

¹<https://fr.wikipedia.org/wiki/Linguistique>

Niveaux d'analyse linguistique

5 grands niveaux d'analyse

- Phonologie
- Morphologie
- Syntaxe
- Sémantique
- Pragmatique

Phonologie

Objectif(s)

- Étudie l'organisation des sons
- Unité minimale : le phonème

Exemples

- J'en veux plus !
- J'ai égaré mes fils...

Morphologie

Objectif(s)

- Étudie la forme des mots
- Unité minimale : le morphème

Flexions

- vais, vas, va, etc
- maisons, maisonnettes

Compositions

- appendicetomie
- appendice + ectomie

Dérivations

- faire, faisable (suffixation)
- infaisable (préfixation)

Emprunts


- abricot (origine : arabe)
 - embarcation (origine : italien)
-

Syntaxe

Objectif(s)

- Étudie les combinaisons de mots (phrases, syntagmes, paragraphes, etc)
- Comment ? En attribuant à chaque mot sa classe grammaticale

Jean observe	la fille	avec le télescope
Jean observe	la fille avec le télescope	



Sémantique

Objectif(s)

- Étudie le sens d'un mot / d'une combinaison de mots
- Unité minimale : le sème

L'analyse sémantique s'appuie entre autre sur...

- le contexte : il tient la porte
- la polysémie : étoile $\Rightarrow$ célébrité ou astre ?
- la syntaxe : Jean observe la jeune fille avec le télescope

Les niveaux d'analyse sont interdépendants.

Pragmatique

Objectif(s)

- Étudie le contexte d'un mot / d'une combinaison de mots
- Contexte : n'est pas limité au langage (lieu, histoire, etc)

Exemples

- La pièce est dans le porte monnaie
 - ici, pièce = argent
 - cotexte VS contexte
- Il fait froid ici...
 - cotexte : ne nous apprend rien
 - contexte : je m'adresse à la personne à côté de la fenêtre ouverte
- C'est une armoire à glace !
 - ???

Pour résumer...

5 grands niveaux d'analyse

- Phonologie $\Rightarrow$ organisation des sons
- Morphologie $\Rightarrow$ forme des mots
- Syntaxe $\Rightarrow$ combinaisons de mots
- Sémantique $\Rightarrow$ sens d'un mot / d'une combinaison
- Pragmatique $\Rightarrow$ contexte d'un mot / d'une combinaison

Modéliser la langue permet de mieux gérer les ambiguïtés.
Techniques du TAL $\approx$ applications de ces analyses.

Exercice

Analysez les énoncés suivants

- Ça fait du bien quand on est lessivés
- T'es vraiment un chips type
- Vous allez avoir des papillons dans le ventre
- *It's raining nems*
- On est champignons d'Europe

Exercice

Analysez les énoncés suivants

- Ça fait du bien quand on est lessivés ⇒ lessive
- T'es vraiment un chips type ⇒ chips
- Vous allez avoir des papillons dans le ventre ⇒ pâtes farfalles
- *It's raining nems* ⇒ nems
- On est champignons d'Europe ⇒ champignons

- ① Avant de commencer...
- ② Introduction à la linguistique
- ③ Techniques du TAL**

Segmentation

Objectif(s)

- Découper un énoncé en phrases / paragraphes
- Permet une analyse plus fine de l'énoncé

Exemples

Bonjour, je suis étudiant A.
Aujourd'hui je vais vous expliquer pourquoi plagier, c'est mal. Dans cet exposé, je vais...

- ⇒
- Bonjour, je suis étudiant A.
 - Aujourd'hui je vais ...
 - Dans cet exposé, je vais ...

Tokenisation

Objectif(s)

- Découper un énoncé en tokens
- Idéalement, 1 mot = 1 token
- Permet de traiter chaque mot indépendamment

Exemples

- Les étudiants mangent un kebab
- pomme de terre ou pomme de terre ?
- tire-bouchon ou tire - bouchon ?
- pierre qui roule n' amasse pas mousse ?

Lemmatisation

Objectif(s)

- Obtenir la forme canonique (lemme) d'un mot
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- Verbe : suis, es, est $\Rightarrow$ être
- Nom : maison, maisonnette, maisons $\Rightarrow$ maison

La lemmatisation n'agrège que des variantes flexionnelles.
chevaux $\Rightarrow$ cheval | chevalier $\neq$ cheval

Racinisation

Objectif(s)


- Obtenir la racine d'un mot (sans flexion et suffixe)
- Agrège beaucoup plus que la lemmatisation
- Permet de "neutraliser" les flexions et variantes lors de l'analyse

Exemples

- cheval, chevaux, chevalier, chevalerie ⇒ cheva
- vais, vas, va, allons, allez, vont ≠ aller

Plus rapide à mettre en place mais moins précise.
avions (verbe) vs avions (nom)

Étiquetage morphosyntaxique



Objectif(s)

- Associer un mot à sa catégorie
- Identifier des structures
- Permet de gérer les ambiguïtés

Exemples

- vers, or, pouvoir, ...

Exercice

Tokenisez les énoncés suivants

- J'ai pris un rendez-vous sur le site de doctolib : <https://www.doctolib.fr/> !
- Budget 2027 : Sébastien Lecornu utilisera-t-il le 49.3 ?
- Jean-Louis travaille à New York. Il étudie les récits de la guerre de 14-18.

Limites

Les techniques du TAL sont limitées

- Des ambiguïtés persistent toujours
- Traiter une langue ne revient pas à traiter toutes les langues
- Les techniques du TAL ne sont pas parfaites

Des inégalités existent

- Langues pas/peu dôtées VS langues dôtées
- Langues sans système d'écriture

Des ambiguïtés persistent

Quelques exemples d'ambiguïtés

- J'en veux plus !
- Appendicetomie
- Jean observe son père avec ses jumelles.
- *He kicked the bucket.*
- Le robot amuse le chat. Il bouge mécaniquement.

Autres types d'ambiguïtés :
ironie, sarcasme, humour, plurilinguisme, etc


Des ambiguïtés persistent

Quelques exemples d'ambiguïtés

- J'en veux plus ! $\Rightarrow$ quel "plus" ?
- Appendicetomie $\Rightarrow$ appendice + ectomie
- Jean observe son père avec ses jumelles. $\Rightarrow$ 3 interprétations
- *He kicked the bucket.* $\Rightarrow$ expression ou description ?
- Le robot amuse le chat. Il bouge mécaniquement. $\Rightarrow$ coréférence

Autres types d'ambiguïtés :
ironie, sarcasme, humour, plurilinguisme, etc

Traiter une langue $\neq$ traiter LES langues




Source : Wikipedia²

Evlerimdekiler (turc) $\Rightarrow$ *ceux qui sont dans les maisons*

²https://en.wikipedia.org/wiki/List_of_languages_by_total_number_of_speakers

Techniques imparfaites



Source : Loretta et. al, 2026³

Étiquetage morphosyntaxique

- 90 %, c'est quoi ?
- Taux d'annotations correctes
- Une phrase en Fr = 10-15 mots
- 90 % $\Rightarrow$ 1 faute par phrase

³<https://www.sciencedirect.com/science/article/pii/S2949719126000312>

Exercice

Identifiez les difficultés propres au traitement de ce texte

Laouen evel an heol eo Yannig hiziv. Peadra zo. Emgav en deus roet da Gatell en ostaleri al Labous-Noz da 6 eur. Bravañ plac'h al lise eo Katell, ha sot eo Yannig ganti. Karout a ra he blev du hir, hag he daoulagad gell-kistin. Ha kement tra a lavar-hi a gav fur, poellek, speredek. Katell a blij dezhañ evel plac'h ebet a-raok. Pemp eur eo bremañ ha mall zo gant Yannig: a-benn un eur e kejo gant e vignonez muiañ karet ha n'eo ket prest c'hoazh! Ret eo dezhañ hastañ buan!

Source : http://www.kervarker.org/fr/dan01_01_skrid.html

Doggy Bag

Analyse linguistique

- Phonétique
- Morphologique
- Syntaxique
- Sémantique
- Pragmatique

Techniques du TAL

- Segmentation
- Tokenisation
- Lemmatisation, racinisation
- Étiquetage morphosyntaxique

