

Découverte du Traitement Automatique des Langues

Hors-série 1 : Les expressions régulières

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



- 1 Avant de commencer...
- 2 Les expressions régulières
- 3 Syntaxe d'une regex

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Références de ce cours

- Gaël Lejeune (gael.lejeune@sorbonne-universite.fr)
 - cours d'ingénierie des langues
- Maxime Amblard (maxime.amblard@univ-lorraine.fr)
 - cours de découverte du TAL

- 1 Avant de commencer...
- 2 Les expressions régulières**
- 3 Syntaxe d'une regex

Un petit test

Identifiez tous les noms et prénoms dans ce texte¹

« Le travail était principalement effectué par son plus jeune fils, Sam Gamegie. Tant le père que le fils étaient en relations très amicales avec Bilbon et Frodon. Ils habitaient sur la Colline même, au numéro 3 du Chemin des Trous-du-Talus, juste sous Cul-de-Sac. »

¹Le Seigneur des anneaux, Tome 1 : La Communauté de l'Anneau de J. R. R. Tolkien

Un petit test

Identifiez tous les noms et prénoms dans ce texte¹

« Le travail était principalement effectué par son plus jeune fils, Sam Gamegie. Tant le père que le fils étaient en relations très amicales avec Bilbon et Frodon. Ils habitaient sur la Colline même, au numéro 3 du Chemin des Trous-du-Talus, juste sous Cul-de-Sac. »

Deux manières pour rechercher des informations

- Recherche en extension : lister toutes les formes attendues
 - Sam, Gamegie, Bilbon, Frodon
- Recherche en intension : définir des règles pour identifier les formes attendues
 - Commence par une majuscule

¹Le Seigneur des anneaux, Tome 1 : La Communauté de l'Anneau de J. R. R. Tolkien

Les expressions régulières

Définition de Wikipédia²

En informatique, une expression régulière est une chaîne de caractères qui décrit, selon une syntaxe précise, un ensemble de chaînes de caractères possibles. Les expressions régulières sont également appelées **regex**.

Les regex permettent d'identifier des motifs dans des textes.
Motif : structure formelle et régulière.

²https://fr.wikipedia.org/wiki/Expression_régulière

Qu'appelle-t-on un motif ?

Motifs institutionnalisés

- Urls
- Adresses mails
- Numéros de téléphone
- Formats d'image (.png, .svg, etc)

Motifs langagiers

- Exemple : trouver les expressions de la forme "prendre la X"
- Ce qu'on cherche : prendre la parole, prendre la porte, etc

Une regex permet de prendre en compte toutes
les variantes possibles d'un motif.

Exercice

Identifiez le motif de...

- Tous les numéros de téléphone français
- Toutes les adresses mails

Utilisez vos mots pour décrire ces motifs !

Solutions possibles

Numéros de téléphone

- 8 nombres, les deux premiers sont listables (01, 03, 06, 07, etc)
- Et pour ces numéros ? $\Rightarrow$ 01 01 23 45 67 || 01-01-23-45-67

Adresses mails

- une séquence + @ + une séquence + un suffixe (.com, .fr, etc)
- bezanconjulien@gmail.com || julien.bezancon@univ-lorraine.fr

Avec des regex

- Numéros : `((\+33)|0)\d9`
- Mails : `[\w\-\.\.]+\@([\w-]+\.)+[\w-]{2,4}`

Quelques règles

Chaque caractère se reconnaît lui-même (majuscules et espaces compris)

- "lapin" reconnaît "lapin", mais pas "Lapin"
- "France 2" ne reconnaît pas "France 3" ou "France2"

Des métacaractères existent

- Les opérateurs
- les quantifieurs

Motif : mélange de caractères et métacaractères.

France \d ⇒ reconnaît "France 2", "France 3", etc

- ① Avant de commencer...
- ② Les expressions régulières
- ③ Syntaxe d'une regex

Opérateurs

()	groupe de caractères
.	n'importe quel caractère
	une expression OU une autre expression
^	condition : expression au début de ligne
\$	condition : expression en fin de ligne
[]	n'importe quel caractère entre les crochets
[^]	n'importe quel caractère qui n'est pas entre les crochets

Quantifieurs

?	une expression 0 ou 1 fois
+	une expression 1 fois ou plus
*	une expression 0 fois ou plus
{n}	une expression exactement n fois
{n,m}	une expression entre n et m fois
{n,}	une expression au moins n fois
{,m}	une expression au plus m fois

Classes de caractères

\w	caractères alphanumériques
\W	caractères autres que alphanumériques
\s	caractères d'espacement
\S	caractères autres que ceux d'espacement
\d	chiffres décimaux
\D	caractères autres que chiffres décimaux

Exercices

Quelles expressions les regex suivantes peuvent-elles identifier ?

- `lo+ng`, `(long)?`, `(lo)*ng`
- `madame|monsieur`, `(madame)|(monsieur)`
- `ver[ts]`, `ver((re)|(ts)|(tige))`
- `chaton{1,3}`, `(chaton){1,3}`, `chaton{1,}`

Trouvez une regex pour exprimer chaque ensemble proposé

- Ensemble 1 : 1742479298, 987654321 , 6754, 42
- Ensemble 2 : aaaa, bbbb, cccc, dddd, eeeee
- Ensemble 3 : les conjugaisons de "aller" au présent
- Ensemble 4 : tous les nombres décimaux

Trucs et astuces

"\" permet de dé-spécialiser des caractères

- \. ⇒ un simple point
- \(⇒ une simple parenthèse

"[]" peut s'utiliser d'une autre manière

- [a-z] ⇒ toutes les lettres de "a" à "z"
- [A-Z] ⇒ toutes les lettres de "A" à "Z"
- [1-9] ⇒ tous les chiffres de "1" à "9"

Un exercice Rock'n'Roll (1/2)

Allez sur le site suivant : <https://regex101.com/>
Sinon, sortez vos crayons !

David Robert Jones, dit **David Bowie** (prononcé en anglais : [ˈdeɪvɪd ˈbəʊi]^{en}, né le 8 janvier 1947 à Londres et mort le 10 janvier 2016 à Manhattan, est un auteur-compositeur-interprète, musicien, acteur et peintre britannique.

Après des débuts entre folk et variété dans la seconde moitié des années 1960 et un détour par le mime, Bowie se fait connaître par le public avec la chanson *Space Oddity* (1969), dans laquelle il présente le personnage du Major Tom, un alter ego qui reviendra régulièrement au long de sa carrière. Il accède à la notoriété en incarnant le personnage flamboyant de Ziggy Stardust, l'une des figures de proue du courant glam rock avec l'album *The Rise and Fall of Ziggy Stardust and the Spiders from Mars* (1972). Bowie s'intéresse aux musiques noires (R'n'B, soul et funk) et s'installe aux États-Unis. Il décroche son premier n° 1 avec la chanson *Fame* issue de l'album *Young Americans* (1975) et crée un alter ego sombre avec le personnage du Thin White Duke et qui aboutit à *Station to Station* (1976). Il s'expatrie avec Iggy Pop à Berlin-Ouest pour se tourner aux côtés de Brian Eno vers la musique électronique. Il produit entre 1977 et 1979 sa « trilogie berlinoise » (*Low*, *"Heroes"* et *Lodger*), considérée comme un de ses sommets artistiques.

David Bowie



David Bowie en 2002.

Informations générales

Nom de naissance

David Robert Jones

Un exercice Rock'n'Roll (2/2)

Créez des regex afin de pouvoir identifier...

- tous les mots
- toutes les années
- toutes les phrases
- les dates complètes
- "David" ou "Bowie" + le mot suivant

Un exercice Rock'n'Roll (2/2)

Créez des regex afin de pouvoir identifier...

- tous les mots $\Rightarrow \text{\code{\w+}}$
- toutes les années $\Rightarrow \text{\code{\d{4}}}$
- toutes les phrases $\Rightarrow \text{\code{\s+|[\^.\! ?]*[\.!\?]}}$
- les dates complètes $\Rightarrow \text{\code{\d{1,2} \w* \d{4}}}$
- "David" ou "Bowie" + le mot suivant $\Rightarrow \text{\code{(David)|(Bowie) ((\w)|([\^ \w \s]))*}}$

Limites

Reprenons le dernier exercice

- Identifiez tous les noms et prénoms
- Identifiez les séquences sujet/verbe/complément
- Identifiez les noms d'album de David Bowie

Les regex ne peuvent pas tout faire.
Elles peuvent devenir dures à lire et comprendre.

```
^[a-z0-9_\. -]+)@([\da-z\.-]+)\.([a-z\.] {2,6})$
```

Pour résumer

Les regex permettent de...

- Retrouver des informations dans un texte
- Exprimer diverses expressions à l'aide d'un unique motif
- Procéder des textes afin de les traiter en TAL

Prochain cours : on reprend le cours de la dernière fois !