Découverte du Traitement Automatique des Langues

CM 4 : Traiter et représenter des données langagières

Julien Bezançon

julien.bezancon@univ-lorraine.fr / `https://julienbez.github.io`





1 Avant de commencer...

2 Représenter des données textuelles

3 Vectorisation : premiers pas

4 Vectorisation : pour aller plus loin

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Doggy bag du dernier cours

Analyse linguistique

- Phonétique
- Morphologique
- Syntaxique
- Sémantique
- Pragmatique

Techniques du TAL

- Segmentation
- Tokenisation
- Lemmatisation, racinisation
- Étiquetage morphosyntaxique



1 Avant de commencer...

2 Représenter des données textuelles

3 Vectorisation : premiers pas

4 Vectorisation : pour aller plus loin

Rappel : le langage selon une machine

Ce que "voit" une machine

Séquence (caractères)	Êl síla erin lû e-govaned vîn

Ce qu'elle ne voit et/ou ne comprend pas

Syntaxe (structure)	Êl síla erin | lû e-govaned vîn
Signifié (sens)	Une étoile brille sur l'heure de notre rencontre
Prosodie (oralité)	*ɛ:l si.la ɛ.rin lu: ɛ go.va.nɛd vi:n*
Contexte	*Vous êtes un hobbit saluant gracieusement un elfe*

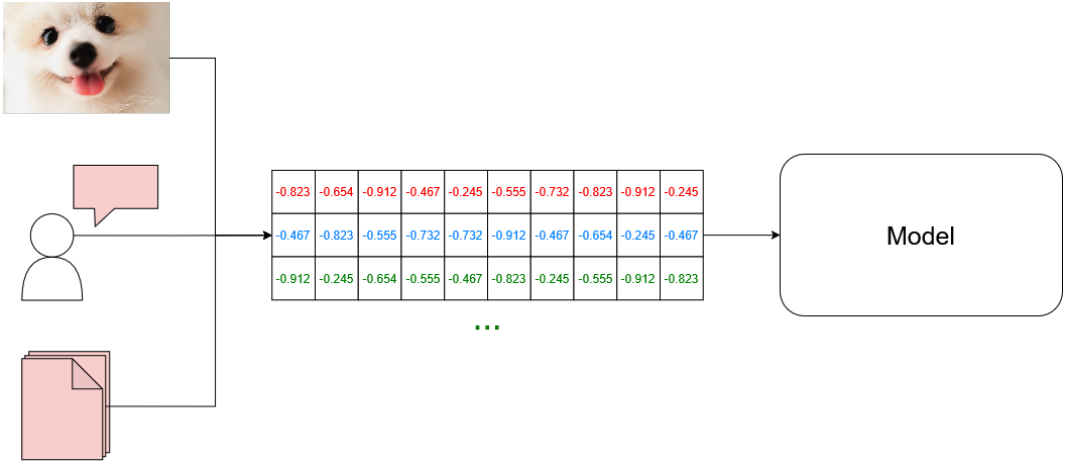
Limites des données textuelles

Limites

- Pas d'analyse sémantique entre les mots
- Peu d'analyse relationnelle entre les mots
- Les modèles statistiques ont besoin de données numériques

Solution : représenter différemment les mots !

Processus de vectorisation des données



Principes de la vectorisation

Objectifs

- Transformer chaque mot en une suite de chiffres ⇒ vecteur
- Capturer des informations contextuelles pour chaque mot
- Capturer des relations entre les mots

Deux intuitions

- Un mot = composé de plusieurs facteurs implicites
  - chat = 10 (animal) + 5 (doux) - 10 (loyal)
- Les vecteurs de deux mots proches devraient être proches
  - "*You shall know a word by the company it keeps*" (Firth, 1957)

Comment vectoriser des données textuelles ?

On a besoin de deux choses

- Des données textuelles (beaucoup de données)
- Une méthode de vectorisation

Données

- Une série de livre ou d'articles
- L'ensemble du contenu de wikipedia
- L'intégralité des données stockées sur internet

Dans la suite de ce cours : les méthodes.

1 Avant de commencer...

2 Représenter des données textuelles

3 Vectorisation : premiers pas

4 Vectorisation : pour aller plus loin

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0
chiens	2	1	1	0	0	0	0	0

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0
chiens	2	1	1	0	0	0	0	0
le	1	0	0	0	0	1	1	1

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0
chiens	2	1	1	0	0	0	0	0
le	1	0	0	0	0	1	1	1
chien	1	0	0	0	1	0	1	1

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0
chiens	2	1	1	0	0	0	0	0
le	1	0	0	0	0	1	1	1
chien	1	0	0	0	1	0	1	1
adore	1	0	0	0	1	1	0	1

Représentation par matrices de co-occurrences

Permet d'obtenir un vecteur par mot/token

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os

	les	humains	adorent	chiens	le	chien	adore	os
les	0	2	2	2	1	1	1	1
humains	2	0	1	1	0	0	0	0
adorent	2	1	0	1	0	0	0	0
chiens	2	1	1	0	0	0	0	0
le	1	0	0	0	0	1	1	1
chien	1	0	0	0	1	0	1	1
adore	1	0	0	0	1	1	0	1
os	1	0	0	0	1	1	1	0

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	2	1	1	1	0	0	0	0

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	2	1	1	1	0	0	0	0
Phrase B	1	0	0	0	1	1	1	1

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	2	1	1	1	0	0	0	0
Phrase B	1	0	0	0	1	1	1	1
Phrase C	2	1	1	1	0	0	0	0

Représentation par sacs de mots

Permet d'obtenir un vecteur par document

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	2	1	1	1	0	0	0	0
Phrase B	1	0	0	0	1	1	1	1
Phrase C	2	1	1	1	0	0	0	0

Quel est le problème ici ?

Un autre exemple

	Antoine & Cléopâtre	Jules César	La Tempête	Hamlet	Othello	Macbeth
Antoine	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
César	232	227	0	2	1	1
Calpurnia	0	10	0	0	0	0
Cléopâtre	57	0	0	0	0	0
pitié	2	0	3	5	5	1
pire	2	0	1	1	1	0

Source : ETAL 2023, Xavier Tannier

On peut "améliorer" les représentations (1/2)

Lemmatisation du texte

- Phrase A : les humains adorent les chiens ⇒ le humain adorer le chien
- Phrase B : le chien adore les os ⇒ le chien adorer le os
- Phrase C : les chiens adorent les humains ⇒ le chien adorer le humain

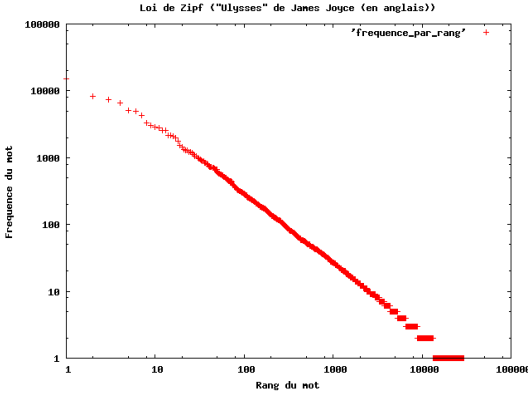
On peut "améliorer" les représentations (1/2)

Lemmatisation du texte

- Phrase A : les humains adorent les chiens ⇒ le humain adorer le chien
- Phrase B : le chien adore les os ⇒ le chien adorer le os
- Phrase C : les chiens adorent les humains ⇒ le chien adorer le humain

	le	humain	adorer	chien	os
Phrase A	2	1	1	1	0
Phrase B	2	0	1	1	1
Phrase C	2	1	1	1	0

Loi de Zipf



Source : wikipedia[1]

[1] https://fr.wikipedia.org/wiki/Loi_de_Zipf

On peut "améliorer" les représentations (2/2)

Intuitions

- Certains mots sont sur-representés dans l'ensemble des textes d'une langue
- De ce fait, ces mots portent moins d'informations sémantiques

⇒ **mots vides** (article, pronom, préposition, conjonction, etc)

On peut "améliorer" les représentations (2/2)

Intuitions

- Certains mots sont sur-representés dans l'ensemble des textes d'une langue
- De ce fait, ces mots portent moins d'informations sémantiques

⇒ **mots vides** (article, pronom, préposition, conjonction, etc)

	humain	adorer	chien	os
Phrase A	1	1	1	0
Phrase B	0	1	1	1
Phrase C	1	1	1	0

Pour résumer : matrices de co-occurrences et sacs de mots

Avantages

- Très simples à créer (on compte des occurrences)
- Compréhensibles par des humains

Inconvénients

- Taille des vecteurs = taille du vocabulaire
- Quid des mots polysémiques ?
- Quid des variantes orthographiques ?
- Quid des expressions multi-mots ?
- Quid des néologismes (mots non-vus) ?

1 Avant de commencer...

2 Représenter des données textuelles

3 Vectorisation : premiers pas

4 Vectorisation : pour aller plus loin

La vectorisation ne s'arrête pas au **comptage** de **mots** !

Nous ne sommes pas limités aux **sacs de mots**.
On peut aller plus loin qu'un simple **comptage**.

Représentation par sacs de N-grammes

Représentation par sacs de N-grammes

Rien ne sert de courir, il faut partir à point

N-grammes de caractères

- Bi-grammes : ri | ie | en | nn | ne ...
- Tri-grammes : rie | ien | enn | nne | nes ...

N-grammes de mots/tokens

- Bi-grammes : rien ne | ne sert | sert de | de courir | courir il ...

C'est dur ? Utilisez l'astuce de la fenêtre !

Pondération TF-IDF

Intuitions

- Compter des mots, c'est quand même un peu limité
- On peut remplacer ce comptage par un calcul

Pondération TF-IDF

- Mesure statistique (bouh des maths)
- Évalue l'importance d'un terme dans un corpus
- Combine deux mesures : le TF et l'IDF

Le TF-IDF permet de pondérer chaque mot.
Un mot très souvent utilisé aura un TF-IDF important.

Comment la calculer ?

TF (term frequency)	IDF (inverted doc. frequency)	TF-IDF
$\frac{N\ terme\ dans\ document}{N\ mots\ dans\ document}$	$log(\frac{N\ documents}{N\ documents\ avec\ terme})$	$TF\ x\ IDF$

En français

- TF : fréquence du terme dans un document
- IDF : inverse de la répartition du terme dans un corpus
- TF-IDF : le produit des deux

Application de la pondération TF-IDF

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

Application de la pondération TF-IDF

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	0.66	0.42	0.42	0.42	0	0	0	0
Phrase B	0.28	0	0	0	0.47	0.47	0.47	0.47
Phrase C	0.66	0.42	0.42	0.42	0	0	0	0

Application de la pondération TF-IDF

- Phrase A : les humains adorent les chiens
- Phrase B : le chien adore les os
- Phrase C : les chiens adorent les humains

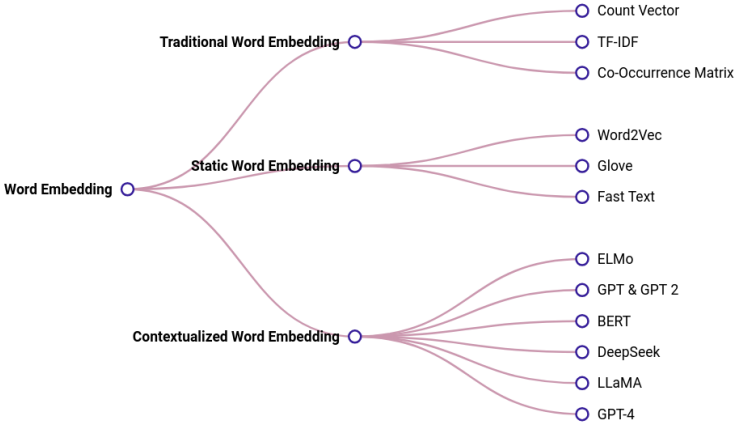
	les	humains	adorent	chiens	le	chien	adore	os
Phrase A	0.66	0.42	0.42	0.42	0	0	0	0
Phrase B	0.28	0	0	0	0.47	0.47	0.47	0.47
Phrase C	0.66	0.42	0.42	0.42	0	0	0	0

Quel problème rencontre-t-on encore ?

Les LLMs utilisent-ils un procédé de vectorisation ?

Oui, mais ils sont bien plus complexes !
(Nous ne les verrons pas pendant ce cours)

Petit aperçu des différentes méthodes



Source : Hesam Sheikh Hassani[2]

[2] https://huggingface.co/hesamation

Pour résumer : vectorisation

Avantages

- Capture d'informations contextuelles pour chaque mot
- Capture des relations entre les mots
- Transforme des données textuelles en données numériques

Inconvénients

- Taille d'un vecteur = taille du vocabulaire
- Il faut trouver des moyens de réduire la taille des vecteurs

Remarque importante

Les vecteurs ne sont que des suites de chiffres !
Ils stockent les informations contextuelles de chaque mot.

En conséquence :

- Vecteur d'un mot ≠ définition d'un mot
- Les représentations sont biaisées par le contenu des corpus

Doggy bag

Vectorisation

- Texte ⇒ vecteurs
- Informations contextuelles
- Relations entre mots

Méthodes

- Matrices de co-occurrences
- Sacs de mots
- N-grammes (char,token)
- Pondération (TF-IDF)

