

Découverte du Traitement Automatique des Langues

Hors-série 1 : Les expressions régulières

Julien Bezançon

julien.bezancon@univ-lorraine.fr / <https://julienbez.github.io>



- 1 Avant de commencer...
- 2 Les expressions régulières
- 3 Opérateurs, quantifieurs et classes

De quoi avons-nous discuté lors du derniers cours ?
Avez-vous des questions ?

Références de ce cours

- Gaël Lejeune (gael.lejeune@sorbonne-universite.fr)
 - cours d'ingénierie des langues
- Maxime Amblard (maxime.amblard@univ-lorraine.fr)
 - cours de découverte du TAL

- 1 Avant de commencer...
- 2 Les expressions régulières**
- 3 Opérateurs, quantifieurs et classes

Un petit test

Identifiez tous les noms et prénoms dans ce texte¹

« Le travail était principalement effectué par son plus jeune fils, Sam Gamegie. Tant le père que le fils étaient en relations très amicales avec Bilbon et Frodon. Ils habitaient sur la Colline même, au numéro 3 du Chemin des Trous-du-Talus, juste sous Cul-de-Sac. »

¹Le Seigneur des anneaux, Tome 1 : La Communauté de l'Anneau de J. R. R. Tolkien

Un petit test

Identifiez tous les noms et prénoms dans ce texte¹

« Le travail était principalement effectué par son plus jeune fils, Sam Gamegie. Tant le père que le fils étaient en relations très amicales avec Bilbon et Frodon. Ils habitaient sur la Colline même, au numéro 3 du Chemin des Trous-du-Talus, juste sous Cul-de-Sac. »

Deux manières pour rechercher des informations

- Recherche en extension : lister toutes les formes attendues
 - Sam, Gamegie, Bilbon, Frodon
- Recherche en intension : définir des règles pour identifier les formes attendues
 - Commence par une majuscule

¹Le Seigneur des anneaux, Tome 1 : La Communauté de l'Anneau de J. R. R. Tolkien

Les expressions régulières

Définition de Wikipédia²

En informatique, une expression régulière est une chaîne de caractères qui décrit, selon une syntaxe précise, un ensemble de chaînes de caractères possibles. Les expressions régulières sont également appelées **regex**.

Les regex permettent d'identifier des motifs dans des textes.
Motif : structure formelle et régulière.

²https://fr.wikipedia.org/wiki/Expression_régulière

Qu'appelle-t-on un motif ?

Motifs institutionnalisés

- Urls
- Adresses mails
- Numéros de téléphone
- Formats d'image (.png, .svg, etc)

Motifs langagiers

- Exemple : trouver les expressions de la forme "prendre la X"
- Ce qu'on cherche : prendre la parole, prendre la porte, etc

Une regex permet de prendre en compte toutes les variantes possibles d'un motif.

Exercice

Identifiez le motif de...

- Tous les numéros de téléphone français
- Toutes les adresses mails

Utilisez vos mots pour décrire ces motifs !

Solutions possibles

Numéros de téléphone

- 8 nombres, les deux premiers sont listables (01, 03, 06, 07, etc)
- Et pour ces numéros ? $\Rightarrow$ 01 01 23 45 67 || 01-01-23-45-67

Adresses mails

- une séquence + @ + une séquence + un suffixe (.com, .fr, etc)
- bezanconjulien@gmail.com || julien.bezancon@univ-lorraine.fr

Avec des regex

- Numéros : `((\+33)|0)\d9`
- Mails : `[\w\-\.\+]+@([\w-]+\.)+[\w-]{2,4}`

Quelques règles

Chaque caractère se reconnaît lui-même (majuscules et espaces compris)

- "lapin" reconnaît "lapin", mais pas "Lapin"
- "France 2" ne reconnaît pas "France 3" ou "France2"

Des métacaractères existent

- Les opérateurs
- les quantifieurs

Motif : mélange de caractères et métacaractères.

France \d ⇒ reconnaît "France 2", "France 3", etc

- 1 Avant de commencer...
- 2 Les expressions régulières
- 3 Opérateurs, quantifieurs et classes**

Opérateurs

()	groupe de caractères
.	n'importe quel caractère
	une expression OU une autre expression
^	condition : expression au début de ligne
\$	condition : expression en fin de ligne
[]	n'importe quel caractère entre les crochets
[^]	n'importe quel caractère qui n'est pas entre les crochets

Quantifieurs

?	une expression 0 ou 1 fois
+	une expression 1 fois ou plus
*	une expression 0 fois ou plus
{n}	une expression exactement n fois
{n,m}	une expression entre n et m fois
{n,}	une expression au moins n fois

Classes de caractères

<code>\w</code>	caractères alphanumériques
<code>\W</code>	caractères autres que alphanumériques
<code>\s</code>	caractères d'espacement
<code>\S</code>	caractères autres que ceux d'espacement
<code>\d</code>	chiffres décimaux
<code>\D</code>	caractères autres que chiffres décimaux

Exercice

Trucs et astuces

"\" permet de dé-spécialiser des caractères

- \. ⇒ un simple point
- \(⇒ une simple parenthèse

"[]" peut s'utiliser d'une autre manière

- [a-z] ⇒ toutes les lettres de "a" à "z"
- [A-Z] ⇒ toutes les lettres de "A" à "Z"
- [1-9] ⇒ tous les chiffres de "1" à "9"